

Estatística Computacional

Inferência Bayesiana - MCMC - Parte 3



Prof. Paulo Cerqueira Jr

Faculdade de Estatística - FAEST

Programa de Pós-graduação em Matemática e Estatística - PPGME

<https://github.com/paulocerqueirajr> 

Introdução

Introdução

- Deseja-se construir um algoritmo de simulação de uma Cadeia de Markov (CM) cuja distribuição limite (estacionária) é alguma distribuição de interesse h , que é:
 1. multidimensional;
 2. e geralmente conhecemos somente o núcleo desta distribuição.
- O interesse principal é obter amostras das distribuições marginais envolvidas em h .
- A ideia é que se deixarmos a CM evoluir, obtemos a partir de um certo tempo T_0 uma amostra aproximada da distribuição conjunta h e também das distribuições marginais de interesse.
- Principais algoritmos: Amostrador de Gibbs e Metropolis-Hastings.

Amostrador de Gibbs

Amostrador de Gibbs

- A construção do algoritmo depende do conhecimento das distribuições condicionais completas.
- A partir da simulação destas distribuições de forma iterativa, podemos obter amostras aproximadas das distribuições marginais.
- Considere o vetor aleatório $\theta = (\theta_1, \theta_2, \dots, \theta_d)$ com função densidade de probabilidade (ou f.p., no caso discreto) conjunta h e seja

$$h(\theta_j \mid \theta_1, \dots, \theta_{j-1}, \theta_{j+1}, \dots, \theta_d),$$

a densidade da j – ésima componente condicional às demais componentes do vetor.

- Essas distribuições são denominadas .

Amostrador de Gibbs

- Suponha que é possível obter um algoritmo de simulação eficiente para simular amostras dessas distribuições.
- Usualmente, em Inferência Bayesiana, é possível obter o núcleo da distribuição conjunta *a posteriori*, mas é difícil obter as distribuições *a posteriori* marginais.
- No caso das distribuições *a posteriori* condicionais terem formas conhecidas (de fácil simulação), o pode ser facilmente implementado.

O algoritmo

1. Fixar um conjunto de valores iniciais $\theta^{(0)} = (\theta_1^{(0)}, \theta_2^{(0)}, \dots, \theta_d^{(0)})$.
2. Obter um novo valor $\theta^{(j)} (\theta_1^{(j)}, \theta_2^{(j)}, \dots, \theta_d^{(j)})$ a partir de um valor $\theta^{(j-1)}$ usando as etapas:
 - a. Gerar $\theta_1^{(j)} \sim h(\theta_1 \mid \theta_2^{(j-1)}, \dots, \theta_d^{(j-1)})$;
 - b. Gerar $\theta_2^{(j)} \sim h(\theta_2 \mid \theta_1^{(j)}, \theta_3^{(j-1)}, \dots, \theta_d^{(j-1)})$;
 - \vdots
 - c. Gerar $\theta_d^{(j)} \sim h(\theta_d \mid \theta_1^{(j)}, \theta_2^{(j)}, \dots, \theta_{d-1}^{(j)})$.
- Mudar o contador de j para $j + 1$ e voltar a etapa 2 até obter a convergência.
- Quando a convergência é atingida, o valor obtido $\theta^{(j)} = (\theta_1^{(j)}, \theta_2^{(j)}, \dots, \theta_d^{(j)})$ é uma amostra da distribuição h .
- Quando o número de iterações cresce, a cadeia se aproxima do equilíbrio, então assume-se que a convergência ocorreu aproximadamente.

Exemplo

No caso do modelo normal quando tem-se $X = (X_1, X_2, \dots, X_n)$ uma amostra aleatória de $X \sim N(\mu, 1/\phi)$, temos a seguinte distribuição **a posteriori**

$$h(\mu, \phi \mid X) \propto \phi^{n/2+a-1} \exp\{-\phi B\} \times (2\pi V)^{-1/2} \exp\left\{-\frac{1}{2V}(\mu - M)^2\right\}$$

Neste caso, as condicional completa para μ :

$$h(\mu, \mid \phi, X) \propto (2\pi V)^{-1/2} \exp\left\{-\frac{1}{2V}(\mu - M)^2\right\}$$

e para ϕ :

$$h(\phi \mid \mu, X) \propto \phi^{n/2+a-1} \exp\{-\phi B\}$$

JAGS (Just Another Gibbs Sampler)

JAGS (Just Another Gibbs Sampler)

- JAGS (Plummer, 2011) é Just Another Gibbs Sampler que foi escrito principalmente por Martyn Plummer para fornecer um motor BUGS para Unix.

Alguns pacotes em [R](#):

- [R2jags](#) (Su e Yajima, 2012) é um pacote R que permite ajustar modelos JAGS de dentro de R. Quase todos os exemplos em Análise de dados de Gelman e Hill usando regressão e multinível/hierárquico Models (2007) pode ser trabalhado de forma equivalente em JAGS, usando R2jags.
- [rjags](#) (Plummer, 2013) é outro pacote R que permite ajustar modelos JAGS de dentro do R. R2jags depende disso. A Análise Bayesiana de Simon Jackman para as Ciências Sociais (2009) fornece muitos exemplos usando rjags, assim como Doing Bayesian Data Analysis (2011), de John Kruschke.
- [runjags](#) (Denwood, N.d.) permite algumas funcionalidades adicionais, incluindo computação paralela.

JAGS (Just Another Gibbs Sampler)

- O JAGS é um compilador que permite realizar análises bayesianas que precisa ser instalado de forma independente do R.
- Os passos de instalação:
 1. Instalar a versão mais recente do [R-Mac](#) ou [R-Win](#)
 2. Instalar o JAGS, versão 3.4.0 do repositório de Martyn Plummer: [JAGS](#)

Exemplo:

```
1 require(runjags)
2 testjags()
```

You are using R version 4.4.0 (2024-04-24 ucrt) on a windows machine,
with the RTerm GUI

JAGS version 4.3.1 found successfully using the command 'C:/Program
Files/JAGS/JAGS-4.3.1/x64/bin/jags-terminal.exe'

The rjags package is installed

Exemplo: Modelagem Gaussiana

- Gerando os dados:

```
1 set.seed(432104)
2 n <- 1000
3 x <- rnorm(n, 0, 5)
```

- Definição do modelo:

```
1 model.Gauss <- "  
2  
3 model {  
4  
5     # Verossimilhança:  
6     for (i in 1:n){  
7         x[i] ~ dnorm(mu, phi)  
8     }  
9  
10    # Priori:  
11    mu ~ dnorm(0,.0001)  
12    phi <- pow(sigma, -2)  
13    sigma ~ dunif(0,100)  
14 }  
15 "
```

Modelagem Gaussiana

Configurações do Amostrador de Gibbs:

```
1 dados <- list(x=x, n=n)
2
3 inits.gen <- list(mu=1, sigma=100)
4
5 param<- c("mu", "sigma", "phi")
6
7 runjags.options(method = "rjags")
8
9 jagsfit <- run.jags(model = model.Gauss,
10                   monitor = param,
11                   data = dados, inits = inits.gen,
12                   adapt = 1000, n.chains = 1, thin = 1,
13                   burnin = 100, sample = 1000)
```

Modelagem Gaussiana

Configurações do Amostrador de Gibbs:

```
1 dados <- list(x=x, n=n)
2
3 inits.gen <- list(mu=1, sigma=100)
4
5 param<- c("mu", "sigma", "phi")
6
7 runjags.options(method = "rjags")
8
9 jagsfit <- run.jags(model = model.Gauss,
10                   monitor = param,
11                   data = dados, inits = inits.gen,
12                   adapt = 1000, n.chains = 1, thin = 1,
13                   burnin = 100, sample = 1000, silent.jags = TRUE)
```

Finished running the simulation

Modelagem Gaussiana




Resumo descritivo da amostra a posteriori:

1 jagsfit\$summaries

	Lower95	Median	Upper95	Mean	SD	Mode
mu	-0.25418093	0.04472057	0.39629698	0.04495132	0.162112915	NA
sigma	4.88180922	5.09456545	5.33132539	5.09844033	0.116410252	NA
phi	0.03518274	0.03852882	0.04196028	0.03853026	0.001755073	NA
	MCerr	MC%ofSD	SSEff	AC.10	psrf	
mu	5.126460e-03	3.2	1000	0.006953886		NA
sigma	4.799784e-03	4.1	588	-0.009542474		NA
phi	7.223208e-05	4.1	590	-0.009119493		NA

Modelagem Gaussiana

```
1 par(mfrow=c(3,1))
2 plot(1:1000, unlist(jagsfit$mcmc[, "mu"]), type="l", ylab="mu")
3 plot(1:1000, unlist(jagsfit$mcmc[, "sigma"]), type="l", ylab="sigma")
4 plot(1:1000, unlist(jagsfit$mcmc[, "phi"]), type="l", ylab="phi")
```



Suporte computacional: pacote CODA (no R)

- Faz gráficos dos valores simulados (trace plots), de auto correlações, de medidas descritivas ergódicas, de estatística de ajuste, auto-correlações.
- Calcula estimativas Bayesianas pontuais e intervalares.
- Uma única amostra de cada parâmetro: matriz em que as linhas são os valores simulados e as colunas são os parâmetros. Transforma num objeto `mcmc`.
- Várias amostras de cada parâmetro: concatenar verticalmente objetos `mcmc` num objeto `mcmc.list`.

Algoritmo de Metropolis-Hastings

- O que fazer quando não conhecemos a forma das distribuições condicionais completas (no sentido de que não a reconhecemos como uma distribuição conhecida)?
- Tem-se que se utilizar algum algoritmo auxiliar para simular dessa densidade:
 1. Metropolis-Hastings (Metropolis-Hastings dentro do amostrador de Gibbs);
 2. rejeição adaptativa;
 3. amostragem por importância;
 4. amostragem por corte “slice sampling”).
- Para as densidades completas que não são conhecidas (e/ou difíceis de simular).

Algoritmo de Metropolis-Hastings

- O algoritmo depende de um núcleo de transição proposto Q e também de uma probabilidade de aceitação $\alpha(\theta, \phi)$ para o valor simulado ϕ , dado que a cadeia está em θ .
- Considere o vetor aleatório $\theta = (\theta_1, \theta_2, \dots, \theta_d)$ com função densidade de probabilidade (ou f.p., no caso discreto) conjunta h e um núcleo de transição Q associado a uma CM da qual sabemos simular.

Algoritmo de Metropolis-Hastings

- a. Fixar um conjunto de valores iniciais $\theta^{(0)} = (\theta_1^{(0)}, \theta_2^{(0)}, \dots, \theta_d^{(0)})$;
- b. Obter um novo valor ϕ simulado de $Q(\theta^{(j-1)}, \cdot)$;
- c. Calcular a probabilidade de aceitação

$$\alpha(\theta, \phi) = \min \left\{ 1, \frac{h(\phi)Q(\phi, \theta)}{h(\theta)Q(\theta, \phi)} \right\};$$

- d. Mover a cadeia para $\theta^{(j)} = \phi$ se $u < \alpha$, em que $u \sim U(0, 1)$. Caso contrário, fazer $\theta^{(j)} = \theta^{(j-1)}$;
- e. Mudar o contador de j para $j + 1$ e voltar a etapa (b) até obter a convergência.

Escolha da distribuição proposta Q:

i. Proposta simétrica: (versão Metropolis).

$$Q(x, y) = Q(y, x), \forall x, y \in S.$$

- Nesse caso,

$$\alpha(\theta, \phi) = \min \left\{ 1, \frac{h(\phi)}{h(\theta)} \right\};$$

- Um exemplo é o uso de um Passeio aleatório: $\theta^{(j)} = \theta^{(j-1)} + \epsilon$;
- Se $\theta \in \mathbb{R}^d$ é usual considerar $\epsilon \sim N_d(0, cV)$.
- A matriz V pode ser definida utilizando-se alguma aproximação da matriz de covariâncias a posteriori.
- O valor c é denominado *tuning constant* (constante de afinação) e pode ser monitorada.

Escolha da distribuição proposta Q:

ii. Proposta Independente:

- A distribuição proposta independe da posição atual da CM, isto é,

$$Q(\theta, \phi) = f(\phi),$$

resultando na seguinte probabilidade de aceitação

$$\alpha(\theta, \phi) = \min \{1, w(\phi)/w(\phi)\},$$

onde $w(x) = h(x)/f(x)$ representa o peso associado ao valor x .

Obs: Se usarmos como proposta a distribuição **a priori**, os pesos w serão dados pela razão de verossimilhanças.

Tamanho efetivo da amostra e autocorrelações

- A autocorrelação de comprimento k (lag k) da CM

$$\rho = \frac{\text{Cov}\left(t^{(n)}, t^{(n+k)}\right)}{\sigma^2},$$

onde σ^2 é a variância de $t^{(n)}$, e t é alguma função de interesse de θ .

- O Tamanho Efetivo da Amostra é dado por

$$N_{eff} = \frac{n}{1 + 2 \sum_{k=1}^{\infty} \rho_k}.$$

Exemplo:

Modelo Weibull:

No caso do modelo normal quando tem-se $X = (X_1, X_2, \dots, X_n)$ uma amostra aleatória de $X \sim Weibull(\alpha, \gamma)$, temos a seguinte distribuição **a posteriori**

$$h(\alpha, \gamma \mid X) \propto L(\alpha, \gamma \mid X)h(\alpha, \gamma)$$

$$\propto L(\alpha, \gamma \mid X)h(\alpha)h(\gamma)$$

$$\propto \alpha^n \gamma^n \left(\prod_{i=1}^n x_i^{\alpha-1} \right) \exp \{ -\gamma \sum_{i=1}^n x_i^\alpha \} \times \frac{b_1^{a_1}}{\Gamma a_1} \alpha^{a_1-1} \exp \{ -b_1 \alpha \}$$

$$\times \frac{b_2^{a_2}}{\Gamma a_2} \alpha^{a_2-1} \exp \{ -b_2 \gamma \}$$

Exemplo:

Modelo Weibull:

A distribuições condicionais completas são:

$$h(\alpha \mid \gamma, X) \propto \alpha^{n+a_1-1} \left(\prod_{i=1}^n x_i^{\alpha-1} \right) \exp \left\{ -\gamma \sum_{i=1}^n x_i^\alpha - b_1 \alpha \right\}$$

$$h(\gamma \mid \alpha, X) \propto \gamma^{n+a_2-1} \exp \left\{ -\gamma \left(\sum_{i=1}^n x_i^\alpha - b_2 \right) \right\}$$

Logo,

$$(\gamma \mid \alpha, X) \sim \text{Gama} \left(n + a_2, \sum_{i=1}^n x_i^\alpha - b_2 \right)$$

$$(\alpha \mid \gamma, X) \sim ???$$